

**Tecnológico Nacional de México**

**Instituto Tecnológico de Culiacán**



**Tópicos de IA**

**Proyecto de Investigación**

**“Sistema de Monitoreo Inteligente y Predictivo de la Calidad del Agua mediante  
Sensores IoT y Redes Neuronales”**

**Maestro: Zuriel Dathan Mora Felix**

**Alumnos:**

**Sandoval Lopez Cesar Ivan**

**Inzunza Flores Daniel Sebastian**

**12-13 hrs**

# índice

<b>1. Introducción .....</b>	<b>3</b>
1.1 Objetivo General.....	4
1.2 Objetivos Específicos .....	4
1.3 Justificación .....	5
1.4 Alcance .....	5
<b>2. Desarrollo .....</b>	<b>6</b>
2.1 El Agua Contaminada como Factor de Riesgo Sanitario Global.....	6
2.2 Indicadores de Calidad del Agua y Sistemas de Evaluación .....	6
2.2.1 Parámetros Clave y Semáforo de Calidad .....	7
2.3 Calidad del agua superficial en México 2024.....	8
2.4 Sensor con IA .....	9
2.5 Aplicación de Redes LSTM en la Predicción .....	10
2.6 Redes Neuronales Convolucionales (CNN).....	10
2.7 Optimización de redes neuronales convolucionales (CNN) para clasificación de turbidez del agua.....	12
2.8 Redes neuronales híbridas CNN-LSTM .....	13
2.8.1 Implementación del Algoritmo para Generación de Dominios con CNN-LSTM .....	13
2.8.2 Redes Híbridas CNN-LSTM para calidad del agua .....	14
2.9 Propuesta Integrada.....	15
2.9.1 Impacto de la propuesta .....	16
<b>3. Cronograma de actividades .....</b>	<b>17</b>
<b>4. Conclusión .....</b>	<b>18</b>
<b>5. Referencias .....</b>	<b>19</b>

## **1. Introducción**

El acceso a agua limpia y segura no es solo un objetivo de desarrollo, sino un pilar fundamental para la supervivencia y el bienestar de las comunidades a nivel global. Sin embargo, este recurso vital enfrenta una amenaza constante y a menudo invisible: la contaminación hídrica. Las cifras hablan por sí solas: la Organización Mundial de la Salud (OMS) estima que anualmente, 400,000 muertes por diarrea se pueden atribuir a la contaminación del agua potable, mientras que la Organización de las Naciones Unidas (ONU) señala que más de 3 mil millones de personas carecen de un monitoreo adecuado de la calidad del agua de la que dependen.

Esta problemática es el resultado de múltiples actividades humanas, incluyendo la urbanización descontrolada, la industrialización y la agricultura, que vierten contaminantes como metales pesados, pesticidas y desechos industriales en nuestros cuerpos de agua. A pesar de la gravedad de este desafío, los métodos de monitoreo tradicionales siguen siendo ineficaces y obsoletos, ya que se basan en la recolección manual de muestras y costosos análisis de laboratorio. Este enfoque reactivo es ineficiente y lento, y nos deja vulnerables ante eventos de contaminación repentinos.

Nuestro proyecto, propone una solución disruptiva que fusiona el Internet de las Cosas (IoT) y la Inteligencia Artificial (IA) para transformar el monitoreo hídrico. Este sistema no solo detecta la contaminación en tiempo real, sino que predice proactivamente posibles eventos de contaminación, facilitando una respuesta inmediata y preventiva. Por lo cual es una herramienta vital para la gestión inteligente y sostenible del agua, alineada con los desafíos del siglo XXI.

## **1.1 Objetivo General**

Diseñar la arquitectura conceptual de un sistema de monitoreo inteligente. Dicho sistema utilizará sensores IoT y modelos de aprendizaje automático para analizar de manera continua y predictiva la calidad del agua, generando alertas tempranas de contaminación en fuentes naturales y redes de suministro.

## **1.2 Objetivos Específicos**

- ❖ Investigación y Selección Tecnológica: Investigar y seleccionar los parámetros críticos de calidad del agua a monitorear (pH, turbidez, conductividad, oxígeno disuelto, entre otros) y las tecnologías de sensores IoT de bajo costo más adecuadas para su medición.
- ❖ Análisis de Modelos de IA: Analizar la aplicación de modelos de Inteligencia Artificial (como Redes Neuronales Convolucionales y Redes de Memoria a Corto Plazo) en la interpretación de datos sensorios y espectrales para la identificación y predicción de contaminantes.
- ❖ Diseño de la Arquitectura Híbrida: Proponer la integración de un sensor óptico de bajo costo en el nodo IoT para capturar las "huellas dactilares" espectrales de los contaminantes, creando una arquitectura de sistema híbrida.
- ❖ Desarrollo del Modelo Predictivo: Diseñar un modelo de IA que combine una CNN para clasificar el tipo de contaminante y una LSTM para predecir tendencias futuras en la calidad del agua.
- ❖ Protocolo de Alertas: Establecer el protocolo para un sistema de alertas automatizadas que notifique a las partes interesadas (agencias, empresas de agua y público) a través de una aplicación web o móvil.

### **1.3 Justificación**

La contaminación del agua es una amenaza silenciosa que puede tener efectos devastadores en cuestión de horas. Los métodos de monitoreo tradicionales, al ser reactivos y depender de análisis de laboratorio lentos y costosos, nos proporcionan información que ya es histórica para el momento en que se procesa. Este enfoque ineficaz nos deja vulnerables a crisis repentinas, permitiendo que el daño a la salud pública y a los ecosistemas ocurra antes de que se pueda tomar una acción.

Nuestro proyecto radica precisamente en el cambio de paradigma que propone: pasar de una gestión de la calidad del agua reactiva a una proactiva y predictiva. No espera a que un contaminante supere un umbral crítico; en su lugar, utiliza el poder de la Inteligencia Artificial para anticipar cuándo ocurrirá un evento de contaminación, funcionando como un pronóstico del tiempo para el agua.

### **1.4 Alcance**

El presente proyecto de investigación se centrará en el diseño conceptual y la validación teórica de la arquitectura. Esto significa que nuestra investigación se dedicará a la creación del marco teórico del sistema, incluyendo la selección de los parámetros clave a monitorear y la propuesta de los modelos de Inteligencia Artificial que se utilizarán para la predicción y el análisis. Es importante destacar que nuestro trabajo no incluye la fabricación física de prototipos, el desarrollo completo de software o la implementación operativa del sistema en el campo.

## **2. Desarrollo**

### **2.1 El Agua Contaminada como Factor de Riesgo Sanitario Global**

El acceso a agua limpia y un saneamiento adecuado son determinantes fundamentales de la salud pública. La gestión inadecuada de las aguas residuales urbanas, industriales y agrícolas contamina las fuentes hídricas, exponiendo a cientos de millones de personas a consumir agua con contaminación biológica (virus, bacterias, helmintos) o química (arsénico, fluoruros, plomo). Esta exposición convierte al agua en un vector de transmisión de enfermedades como el cólera, la disentería, la hepatitis A, la fiebre tifoidea y la poliomielitis, cuya consecuencia más inmediata y devastadora son las enfermedades diarreicas.

La magnitud del problema es alarmante. Se estima que cerca de un millón de personas fallecen anualmente por enfermedades diarreicas vinculadas a agua insalubre, siendo los 395,000 niños menores de cinco años una cifra que evidencia la vulnerabilidad de la población infantil y la previsibilidad de estas muertes. Además, la falta de agua segura en los entornos sanitarios amplifica el riesgo, donde las infecciones asociadas a la atención sanitaria (IAAS) afectan a 15 de cada 100 pacientes en países de ingresos bajos y medios.

Por lo tanto, la contaminación hídrica no es solo un asunto ambiental, sino una crisis de salud pública prevenible. La implementación de soluciones de monitoreo efectivo se erige como una estrategia crucial para mitigar este riesgo, proporcionando datos oportunos que permitan acciones intervenciones tempranas y romper la cadena de transmisión de enfermedades.

### **2.2 Indicadores de Calidad del Agua y Sistemas de Evaluación**

Los indicadores de calidad del agua son herramientas cuantitativas esenciales para evaluar el estado de los cuerpos de agua superficiales y subterráneos. Estos parámetros permiten determinar la aptitud del agua para diversos usos, como el consumo humano, el riego agrícola y la preservación de los ecosistemas. En México, la Gerencia de Calidad del Agua de la CONAGUA utiliza un sistema basado en el monitoreo de la Red Nacional de Medición de la Calidad del Agua (RENAMECA), que clasifica los resultados mediante un semáforo de calidad (verde,

amarillo, rojo) según el cumplimiento de los límites establecidos para cada parámetro.

### **2.2.1 Parámetros Clave y Semáforo de Calidad**

#### **Agua Superficial:**

Se evalúa mediante 8 indicadores:

1. Demanda Bioquímica de Oxígeno (DBO), Demanda Química de Oxígeno (DQO), Sólidos Suspendidos Totales (SST): reflejan contaminación orgánica y material particulado.
2. Coliformes fecales (CF), Escherichia coli (E\_COLI), Enterococos (ENTEROC): indicadores de contaminación microbiológica.
3. Oxígeno Disuelto (OD\_PORC): crucial para la vida acuática.
4. Toxicidad aguda (TOX): evalúa efectos letales en organismos.

#### **Semáforo:**

- Rojo: Incumplimiento en al menos uno de DBO, DQO, ENTEROC o TOX.
- Amarillo: Cumplimiento en los anteriores, pero incumplimiento en SST, OD\_PORC, CF o E\_COLI.
- Verde: Cumplimiento total.

#### **Agua Subterránea:**

Se analizan 14 parámetros, incluyendo:

- Contaminantes críticos: Fluoruros, Nitratos, Metales pesados (Arsénico, Cadmio, Plomo, Mercurio).
- Propiedades físico-químicas: Conductividad, Dureza, Sólidos Disueltos Totales (SDT).

#### **Semáforo:**

- Rojo: Incumplimiento en fluoruros, coliformes fecales, nitratos o metales pesados.
- Amarillo: Incumplimiento en parámetros como alcalinidad, conductividad o hierro.

- Verde: Cumplimiento total.

### **2.3 Calidad del agua superficial en México 2024**

En el año 2024, la Red Nacional de Monitoreo de la Calidad del Agua (RENAMECA) evaluó 636 sitios superficiales en México para determinar el estado de los cuerpos de agua del país. Los resultados mostraron diferencias importantes según el indicador analizado. Por ejemplo, de acuerdo con la Demanda Bioquímica de Oxígeno (DBO), el 30.2% de los sitios se calificó como excelente; con la Demanda Química de Oxígeno (DQO), el 23.6%; con Sólidos Suspendedos Totales (SST), el 52.9%; con Coliformes Fecales (CF), apenas el 16.5%; y con *Escherichia coli* (E. coli), únicamente el 12.4%. En contraste, con Enterococos (ENTEROC) todos los sitios obtuvieron un 100% de excelencia, mientras que con el indicador de oxígeno disuelto (OD\_PORC), el 46% de los sitios alcanzó calificaciones óptimas. Cabe destacar que en cuanto a toxicidad aguda, el 95.3% de los sitios no presentó problemas, lo cual refleja un panorama relativamente positivo en este aspecto.

Al aplicar el sistema de semáforo para representar de manera más sencilla la calidad del agua superficial, los resultados fueron los siguientes: el 31.9% de los sitios se colocaron en color verde (indicando buena calidad), el 19.5% en amarillo (riesgo moderado) y el 48.6% en rojo, lo que significa que casi la mitad de los sitios presentan problemas significativos de contaminación. Esto pone de manifiesto que, aunque algunos indicadores muestran avances, todavía existe un porcentaje alto de cuerpos de agua con calidad deficiente.

En cuanto a la calidad del agua subterránea en 2024, la evaluación se enfocó en su aptitud para el abastecimiento de agua potable y el riego agrícola, considerando 466 sitios monitoreados. Los resultados fueron en general positivos para algunos parámetros: el cumplimiento fue del 100% en coliformes fecales, cromo total y mercurio total; del 98.1% en manganeso total; del 97.3% en sólidos disueltos totales; del 97.2% en hierro total; y del 94.8% en conductividad. Otros parámetros mostraron porcentajes más bajos, como alcalinidad (94%), nitratos (91.6%), dureza (87.7%), cadmio total (79.4%), arsénico total (72.5%) y plomo total junto con fluoruros (67.5%), lo que refleja áreas de riesgo importantes.



Al igual que en el caso del agua superficial, se aplicó un semáforo para representar la calidad del agua subterránea. Los resultados indicaron que el 45.5% de los sitios se encuentra en verde, lo que significa buena calidad para el uso humano y agrícola; el 9% en amarillo, representando calidad intermedia; y otro 45.5% en rojo, lo cual refleja un problema considerable en casi la mitad de los sitios evaluados.

## **2.4 Sensor con IA**

La consultoría de ingeniería y medio ambiente Aecom ha desarrollado un biosensor innovador que mide en tiempo real el nivel de contaminación del agua. El dispositivo se basa en un biofilm formado por microalgas y bacterias, que actúan como un detector biológico de toxicidad. Gracias a esta tecnología, el biosensor no solo identifica la presencia de contaminantes, sino que también compara los resultados obtenidos con las previsiones de calidad mediante el uso de inteligencia artificial.

De acuerdo con la investigadora principal, Roberta Carafa, este biosensor representa un gran avance en el sector porque permite un control proactivo de la calidad del agua, en contraste con los métodos tradicionales que suelen ser reactivos y tardíos, ya que dependen de la aparición de episodios graves de contaminación para actuar. Además, el dispositivo no sustituye a los análisis convencionales, sino que los complementa, ofreciendo información en tiempo real y de gran sensibilidad, incluso detectando concentraciones de contaminantes de hasta un microgramo por litro.

Una de las características más destacadas de este biosensor es su adaptabilidad. Puede funcionar en diferentes tipos de agua: dulce, marina o de transición, simplemente cambiando el biofilm utilizado en las pequeñas cámaras del dispositivo. Esto lo convierte en una herramienta flexible y útil en una amplia variedad de contextos, desde ríos urbanos hasta ecosistemas costeros.

El papel de la inteligencia artificial en este sistema es crucial, ya que los algoritmos desarrollan modelos de predicción de contaminación a corto y mediano plazo. De esta manera, no solo se detectan los niveles actuales de toxicidad, sino que también se anticipan posibles problemas en minutos, días o incluso semanas. En caso de

que los valores medidos difieran significativamente de las previsiones, el dispositivo activa una alarma para que las autoridades competentes puedan tomar decisiones inmediatas y realizar análisis más detallados.

## **2.5 Aplicación de Redes LSTM en la Predicción**

Las Long Short-Term Memory (LSTM) representan una evolución fundamental en el modelado de series temporales debido a su capacidad inherente para capturar dependencias de largo plazo en secuencias temporales. A diferencia de los modelos tradicionales como ARIMA o las RNN estándar, las LSTM incorporan un mecanismo de compuertas que permite preservar información relevante a través de intervalos temporales extendidos. Esta característica es particularmente valiosa en series temporales con patrones estacionales complejos, tendencias no lineales o eventos disruptivos, donde la relación entre observaciones distantes en el tiempo resulta crucial para predicciones precisas.

La arquitectura de las LSTM se compone de tres compuertas fundamentales que regulan el flujo de información: la compuerta de olvido determina qué información previa debe ser descartada, la compuerta de entrada decide qué nueva información se almacenará en el estado de la celda, y la compuerta de salida controla la información que se propagará al siguiente paso temporal. Este diseño permite que la red aprenda automáticamente qué información retener y qué descartar, adaptándose dinámicamente a las características específicas de la serie temporal analizada. Para problemas de predicción, se utilizan configuraciones many-to-one, donde la red procesa una ventana deslizante de valores históricos para generar una predicción puntual futura.

## **2.6 Redes Neuronales Convolucionales (CNN)**

Las Redes Neuronales Convolucionales (CNN), tradicionalmente asociadas al procesamiento de imágenes, han demostrado ser excepcionalmente efectivas en el análisis de series temporales, incluyendo la predicción de parámetros de calidad del agua. Su adaptación a datos temporales se realiza mediante el uso de capas convolucionales unidimensionales (1D), que operan de manera análoga a como lo harían en imágenes 2D, pero aplicando filtros a lo largo de una única dimensión: el

tiempo. Esta capacidad les permite identificar patrones locales, tendencias y correlaciones entre variables en ventanas temporales específicas para detectar eventos abruptos, como contaminaciones puntuales o cambios estacionales rápidos en cuerpos de agua.

La arquitectura típica de una CNN para series temporales consta de varias capas convolucionales 1D intercaladas con capas de pooling. Las capas convolucionales se encargan de extraer características relevantes aplicando kernels o filtros que se deslizan a lo largo de la secuencia temporal. Por ejemplo, un filtro podría aprender a reconocer una subida simultánea de temperatura y disminución de oxígeno disuelto, un patrón común en episodios de contaminación térmica. Las capas de pooling (como MaxPooling1D) reducen la dimensionalidad de los datos, conservando la información más significativa y aportando invariancia a pequeñas variaciones temporales, lo que mejora la eficiencia computacional y reduce el sobreajuste. Finalmente, las capas fully connected interpretan estas características para generar predicciones concretas, como los niveles futuros de turbiedad o la concentración de un contaminante específico.

Entre las ventajas más destacables de las CNN para esta aplicación se encuentra su velocidad de entrenamiento, notablemente superior a la de las redes recurrentes como las LSTM, debido a la naturaleza paralela de las operaciones convolucionales. Además, su capacidad para manejar valores atípicos mediante técnicas como el padding y su robustness ante el ruido en las mediciones gracias a la filtración inherente que proporcionan los kernels las hacen ideales para entornos de monitorización con datos imperfectos. Sin embargo, una limitación importante es que, por diseño, las CNN no capturan dependencias temporales a muy largo plazo tan eficientemente como las LSTM, por lo que suelen ser más adecuadas para predicciones a corto plazo o para patrones con ciclos bien definidos. Aplicaciones prácticas incluyen la detección en tiempo real de vertidos contaminantes, la predicción de florecimientos algales (blooms) o la monitorización continua en estaciones de tratamiento de aguas. La combinación de CNN con sensores de bajo costo y LSTM facilitará el despliegue de sistemas de monitoreo predictivo accesibles

y escalables, capaces de alertar sobre cambios críticos en la calidad del agua con la antelación necesaria para tomar medidas correctivas.

## **2.7 Optimización de redes neuronales convolucionales (CNN) para clasificación de turbidez del agua**

El artículo se centra en el uso de redes neuronales convolucionales (CNN) para clasificar imágenes de agua según su turbidez. La turbidez es un parámetro crítico de calidad del agua porque refleja la claridad y puede indicar la presencia de partículas suspendidas que afectan salud humana y ecosistemas. Métodos tradicionales de medición (como espectrofotometría o dispersión de luz) son precisos pero costosos y poco prácticos para monitoreos frecuentes o en campo.

Para abordar estos retos, los autores prepararon un conjunto de datos con imágenes de distinta turbidez, usando soluciones de  $\text{CaCO}_3$  en agua destilada para crear 10 niveles distintos de turbidez. Estos niveles se midieron con un turbidímetro portátil (HI98703) para tener una referencia confiable en unidades NTU. Luego se tomaron fotografías de estas muestras bajo condiciones controladas: misma fuente de luz, mismo recipiente, misma temperatura, con la idea de que la diferencia visual entre niveles de turbidez puede ser muy sutil y difícil de distinguir al ojo humano.

Una parte clave del estudio fue introducir ruido en las imágenes (por ejemplo, ruido gaussiano, ruido mixto) para simular condiciones realistas, pues en aplicaciones prácticas las imágenes no serán perfectas. También se experimentó con recortar imágenes (crop) para enfocarse en la región de interés y reducir efectos distractores, y con procesamiento para extracción de características como energía en niveles de gris, energía de gradiente, entropía, varianza, etc.

Los autores probaron cuatro arquitecturas de CNN: un modelo de 8 capas, uno de 10, cada uno tanto con “dropout” (una técnica para reducir sobreajuste) y sin ello. Evaluaron los modelos en conjuntos de datos limpios (“noise-free”) y con ruido añadido. Los resultados muestran que el modelo CNN-10 con dropout alcanza un 96.5 % de precisión en imágenes con ruido, lo cual es muy alto. En datos sin ruido, los modelos también se desempeñan muy bien, aunque con una diferencia menor

Finalmente, se discuten limitaciones: modelos más complejos dan mejor precisión, pero cuesta más en tiempo de cómputo y demanda más recursos, lo que puede dificultar su uso en campo o en dispositivos con poca capacidad. Además, aunque el experimento abarcó situaciones con ruido, aún queda por evaluar la generalización en distintos escenarios reales (diferente iluminación, condiciones de agua reales, cámaras, etc.). Como siguientes pasos se sugiere explorar optimizaciones para reducir el costo computacional, incorporar más tipos de ruido, y combinar varios modelos para mejorar robustez

## **2.8 Redes neuronales híbridas CNN-LSTM**

### **2.8.1 Implementación del Algoritmo para Generación de Dominios con CNN-LSTM**

En el presente subtema se detalla la implementación del algoritmo de generación de dominios mediante el uso de Keras. El enfoque principal se centra en cómo se configuró y entrenó la red neuronal híbrida para generar nombres de dominio que presentaran similitud estructural y contextual con los dominios considerados normales.

La arquitectura implementada consistió en una red neuronal híbrida que combina capas convolucionales 1D y capas LSTM. Las capas convolucionales se emplearon para extraer patrones locales y características relevantes de las secuencias de caracteres, mientras que las capas LSTM permitieron capturar dependencias temporales a largo plazo en la estructura de los dominios. Esta combinación resultó efectiva para aprender tanto las subestructuras comunes en los nombres de dominio como las relaciones contextuales entre caracteres.

Para el entrenamiento del modelo, se utilizó el optimizador Adam con una tasa de aprendizaje de 0.01. El modelo se compiló utilizando la función de pérdida categorical crossentropy, adecuada para problemas de clasificación multiclase como la generación de caracteres secuenciales. Durante el proceso de entrenamiento, se realizaron múltiples experimentos con distintos valores de épocas, tamaño de batch y otros hiperparámetros, determinando que la configuración mencionada demostró ser la más efectiva para la tarea.

El proceso de generación de dominios se realizó mediante muestreo aleatorio con un valor de diversidad de 0.5. En cada época se seleccionaba aleatoriamente una secuencia inicial del texto de entrenamiento, a partir de la cual la red generaba 400 caracteres adicionales. Este enfoque permitió la generación de aproximadamente 9 nombres de dominio por época, los cuales se utilizaron para evaluar cualitativamente el progreso del modelo en términos de coherencia y similitud con dominios reales.

La implementación completa del código se encuentra disponible en el repositorio público de GitHub dado por el usuario, donde se pueden consultar los detalles específicos de la arquitectura y los parámetros de entrenamiento. Los resultados demostraron que este enfoque permitió a la red neuronal generar nombres de dominio consistentes y realistas, cumpliendo con el objetivo principal del estudio de generar dominios similares a los normales.

### **2.8.2 Redes Híbridas CNN-LSTM para calidad del agua**

La arquitectura de red neuronal implementada en esta investigación se basa en una combinación híbrida de redes neuronales convolucionales y redes de memoria a largo plazo. Esta elección se fundamenta en la necesidad de procesar datos secuenciales multivariantes donde es esencial capturar tanto patrones locales en ventanas temporales cortas como dependencias temporales a largo plazo. La integración de estos dos tipos de arquitecturas permite aprovechar sus ventajas complementarias para el análisis de series temporales complejas.

El diseño comienza con una capa convolucional unidimensional que se encarga de extraer características relevantes de los datos de entrada. Esta capa opera mediante filtros que se deslizan a lo largo de la dimensión temporal, identificando patrones locales y correlaciones entre las diferentes variables en intervalos temporales específicos. La capacidad de estas capas para detectar características significativas en segmentos reducidos de la serie temporal constituye la primera etapa del procesamiento.

Después, se incorpora una capa de agrupación máxima que reduce la dimensionalidad de las características extraídas. Esta operación conserva la

información más relevante identificada por los filtros convolucionales mientras disminuye la complejidad computacional del modelo. El proceso de agrupamiento permite destacar las características más significativas y proporciona cierto grado de invariancia temporal a pequeñas variaciones en los datos.

Posteriormente, la arquitectura integra una capa de memoria a largo plazo que procesa la secuencia de características extraídas. Esta componente está específicamente diseñada para capturar dependencias temporales a largo plazo y aprender la dinámica subyacente en la evolución temporal de los parámetros. Su mecanismo de compuertas permite conservar información relevante a través de intervalos temporales extendidos, superando las limitaciones de las redes recurrentes tradicionales.

La red culmina con una capa dense que realiza la predicción final de los parámetros objetivo. Esta capa sintetiza toda la información procesada por las componentes anteriores y genera las salidas numéricas correspondientes. La arquitectura completa permite un procesamiento jerárquico de los datos, donde se identifican primero patrones locales para después contextualizarlos temporal y finalmente producir las predicciones deseadas.

## **2.9 Propuesta Integrada**

Nuestro proyecto propone una solución híbrida y mejorada que combina IoT e IA:

- Captura de datos multivariables: sensores IoT de bajo costo medirán parámetros como turbidez, pH, oxígeno disuelto y conductividad.
- Visión por computadora: una CNN ligera optimizada analizará imágenes del agua, entrenada con datasets mixtos (laboratorio + campo) y aumentados artificialmente para simular ruido, cambios de iluminación y diferentes dispositivos de captura.
- Predicción temporal: una LSTM (Long Short-Term Memory) se integrará al sistema para predecir tendencias futuras en los parámetros de calidad, permitiendo anticipar eventos de contaminación.
- Arquitectura IoT-IA: el modelo se ejecutará en dispositivos de bajo consumo energético, con capacidad de envío de datos a la nube.

- Protocolo de alertas: un sistema de notificaciones en tiempo real (web y móvil) alertará a autoridades, empresas de agua y comunidades, permitiendo una respuesta preventiva y no solo reactiva.

### **2.9.1 Impacto de la propuesta**

La implementación de esta propuesta tendría un alto impacto ambiental y social, ya que:

- Democratiza el acceso al monitoreo de agua al usar sensores económicos y accesibles.
- Permite detectar contaminaciones en tiempo real, reduciendo riesgos de enfermedades transmitidas por el agua.
- Protege ecosistemas acuáticos al identificar eventos de turbidez anómalos antes de que causen daños irreversibles.
- Favorece la gestión proactiva y sostenible del recurso hídrico, alineándose con los Objetivos de Desarrollo Sostenible (ODS 6: Agua limpia y saneamiento).
- Promueve la transición hacia un modelo de gestión inteligente y predictiva del agua, en vez de uno reactivo.



### 3. Cronograma de actividades

TAREAS	AGOSTO				SEPTIEMBRE				OCTUBRE				NOVIEMBRE				DICIEMBRE			
Revisión Bibliográfica Exhaustiva																				
Definición de Alcance y Objetivos Finales																				
Estado del Arte: Sensores IoT y IA																				
Selección de Parámetros Críticos																				
Investigación de Tecnologías de Sensores																				
Diseño Arquitectura IoT (Flujo de Datos)																				
Investigación Arquitecturas CNN y LSTM																				
Diseño Arquitectura Híbrida CNN-LSTM																				
Redacción Continua del Documento																				
Validación Teórica y Cohesión																				
Revisión Final, Edición y Entrega																				

#### **4. Conclusión**

Para superar las limitaciones de los métodos tradicionales de monitoreo, que son reactivos y lentos, la innovación tecnológica se presenta como una estrategia indispensable. La convergencia del Internet de las Cosas (IoT) y la Inteligencia Artificial (IA) ofrece una solución robusta y proactiva. Como lo demuestra el biosensor de Aecom y las redes neuronales avanzadas, es posible no solo detectar contaminantes en tiempo real con alta sensibilidad, sino también anticipar episodios de riesgo antes de que ocurran.

La arquitectura de red neuronal híbrida CNN-LSTM se consolida como el modelo más eficaz para esta tarea. Al combinar la capacidad de las CNN para identificar patrones locales y eventos abruptos, con la habilidad de las LSTM para capturar dependencias temporales a largo plazo, se logra una precisión predictiva superior. Este enfoque permite que un sistema de monitoreo como el que se está planteando no solo evalúe el estado actual del agua, sino que también genere pronósticos fiables, transformando la gestión de recursos hídricos de una práctica de respuesta a una de prevención. En definitiva, la tecnología nos permite pasar del simple monitoreo a una gestión inteligente, predictiva y proactiva, un paso crucial para garantizar la seguridad y sostenibilidad de nuestro recurso más valioso.

## 5. Referencias

<https://www.who.int/es/news-room/fact-sheets/detail/diarrhoeal-disease>

<https://sdgs.un.org/goals/>

<https://www.nature.com/articles/s41598-025-93521-4>

<https://www.who.int/es/news-room/fact-sheets/detail/drinking-water>

<https://www.gob.mx/conagua/articulos/indicadores-de-calidad-del-agua>

<https://www.residuosprofesional.com/biosensor-ia-medir-contaminacion-agua/>

[https://sedici.unlp.edu.ar/bitstream/handle/10915/165065/Documento\\_completo.pdf-PDFA.pdf?sequence=1&isAllowed=y](https://sedici.unlp.edu.ar/bitstream/handle/10915/165065/Documento_completo.pdf-PDFA.pdf?sequence=1&isAllowed=y)

<https://repositorio.utp.edu.co/entities/publication/9ec41982-5d62-46b0-ae3d-ca17f406eabd>

REPOSITORIO GITHUB --> <https://github.com/CesarIsL/Topicos-IA>